

Herond Robaina Salles

*Clustering de imagens via redes neurais de
Kohonen associadas a descritores de Hu*

Campos dos Goytacazes/RJ

2012

Herond Robaina Salles

*Clustering de imagens via redes neurais de
Kohonen associadas a descritores de Hu*

Monografia apresentada ao Curso de Graduação em Ciência da Computação da Universidade Estadual do Norte Fluminense Darcy Ribeiro como requisito para obtenção do título de Bacharel em Ciência da Computação, sob orientação da Prof^a. Annabell Del Real Tamariz, DrSc.

Tutor: Annabell Del Real Tamariz, DrSc.

UNIVERSIDADE ESTADUAL DO NORTE FLUMINENSE DARCY RIBEIRO

Campos dos Goytacazes/RJ

2012

“E posto que se infligiram inutilmente ao corpo social tantos sistemas, que se termine por onde se deveria ter começado: que se rejeitem os sistemas; que se coloque, por fim, a Liberdade à prova - a Liberdade, que é um ato de fé em Deus e em sua obra.”

Frederic Bastiat

AGRADECIMENTOS

À meu pai, minha mãe e especialmente à você.

Lista de Figuras

Lista de Códigos

Resumo

Aqui entra o resumo do meu trabalho que será a última coisa a ser feita.

Sumário

Lista de Figuras	2
Resumo	4
1 Introdução	6
1.1 Organização	6
2 Fundamentos teóricos	7
2.1 Redes neurais artificiais	7
2.2 Principais tipos de redes neurais	8
2.2.1 Rede perceptron multicamada	8
2.2.2 Rede de Hopfield	8
2.2.3 Redes de Kohonen	9
2.3 Redes neurais de Kohonen	10
2.3.1 Topologia de uma rede de Kohonen	10
2.3.2 Treinamento da rede	10
2.4 Descritores de Hu	13
2.5 Imagens digitais	15
2.5.1 Mapas de bits	15
2.5.2 Imagens vetoriais	16
Referências Bibliográficas	17

1 *Introdução*

Clusters de imagens são agrupamentos de imagens digitais segundo determinadas características de similaridade, em geral cores, formas ou textura; o mapeamento deve ocorrer de tal forma que cada classe forneça, essencialmente, as mesmas informações sobre as imagens que a compõem. As técnicas de *clustering* associadas a mecanismos de classificação podem fornecer um resumo conciso do conteúdo das imagens, podendo ser utilizado para diferentes tarefas relacionadas com a gestão de banco de dados de imagens. Entre os principais usos dos *clusters* de imagens são: catálogos de arte, banco de imagens fotográficas, diagnósticos médicos, computação forense e classificação de informações geográficas e de sensoriamento remoto.

Este trabalho tem o objetivo de descrever e demonstrar a viabilidade de um algoritmo não supervisionado de *clustering* de imagens baseado numa rede neural artificial de Kohonen, utilizando como caracterizadores das imagens os descritores de Hu. Para alcançar este objetivo, além de toda pesquisa teórica acerca dos métodos utilizados, uma aplicação real foi desenvolvida para testar a validade do algoritmo proposto.

1.1 Organização

Este trabalho está organizado da seguinte maneira.

No capítulo 2 é feita uma descrição geral dos métodos utilizados, abordando os principais conceitos acerca de redes neurais artificiais, em especial das redes de Kohonen, dos descritores de Hu e das imagens digitais. No capítulo 3 é formalizado o algoritmo de *clustering* proposto, bem como a justificativa para a utilização dos métodos descritos no capítulo 2; ainda no capítulo 3 os resultados de um conjunto de teste são apresentados e discutidos. No capítulo 4 são extraídas as conclusões e apresentadas as perspectivas de trabalhos futuros.

2 *Fundamentos teóricos*

Este capítulo descreve os principais elementos teóricos utilizados no desenvolvimento desta pesquisa. As seções 2.1 e 2.2 resumem os principais conceitos sobre redes neurais, assim como as principais técnicas utilizadas nesta área. A seção 2.3 é dedicada especificamente as redes de Kohonen, descrevendo sua estrutura conceitual e seu algoritmo de treinamento, esta categoria de rede neural é o núcleo da técnica de *clustering* de imagens proposta neste trabalho, assunto abordado no próximo capítulo. Uma breve formalização dos descritores de Hu é feita na seção 2.4. E por fim, alguns conceitos chave sobre imagens digitais são apresentados na seção 2.5.

2.1 Redes neurais artificiais

Dentro da Inteligência artificial, mais especificamente no contexto do aprendizado de máquina, as redes neurais artificiais são sistemas computacionais inspirados na estrutura do cérebro, em particular dos neurônios, que adquirem conhecimento através da experiência.

As redes neurais se assemelham a grafos direcionados, onde os nós são os neurônios, ou unidades de processamento, que possuem uma quantidade indefinida de conexões de entrada e saída. As conexões são o equivalente às arestas do grafo, e são responsáveis por transmitir informações entre os neurônios, podendo amplificar ou reduzir a acuidade destas informações.

$$\sum f$$

Sinais de entrada provenientes de fora da rede chegam por meio de conexões originadas do mundo externo, de modo semelhante, saídas da rede para o mundo externo são conexões

que deixam a rede.

A configuração da rede, ou seja, os pesos atuais das conexões, determina como os dados de entrada irão ativar os diferentes neurônios e gerar um determinado resultado. Para grande maioria dos tipos de redes neurais, uma configuração particular é obtida através de um algoritmo de treinamento. O treinamento em geral busca reforçar as conexões que geram bons resultados e penalizar as que não geram.

Entre as tarefas para as quais uma rede neural é adequada se incluem: classificação, reconhecimento de padrões, previsões, otimização e filtragem de ruído.

2.2 Principais tipos de redes neurais

Dentre a grande variedade de tipos de redes neurais artificiais, as mais importantes, seja por sua contribuição teórica ou pela praticidade, são:

2.2.1 Rede perceptron multicamada

A perceptron multicamada é (a) uma rede direta, isto é, o sinal passa da entrada até a saída sem ciclos; (b) possui camadas intermediárias de neurônios entre as camadas de entrada e saída, ditas camadas ocultas; (c) utiliza funções de ativação não lineares, comumente a função sigmoide e (d) os neurônios são altamente conectados, em geral cada neurônio é conectado a todos os neurônios da camada anterior e da camada seguinte.

ESQUEMA DE UMA REDE PERCEPTRON MULTICAMADA AQUI

A presença de múltiplas camadas permite a este tipo de rede resolver uma enorme variedade de problemas, ou em outros termos, reconhecer uma vasta variedade de padrões. As redes multicamadas são computacionalmente completas, ou seja, são equivalentes à classe das máquinas de Turing.

A retropropagação é o algoritmo de treinamento mais utilizado para esta variante de rede neural. Cada iteração deste algoritmo é dividido em dois passos, no primeiro a rede é alimentada com um dos exemplos, o resultado é capturado e comparado com o valor esperado, com isso o erro geral da rede é calculado; segue-se então ao segundo passo, que atualiza os pesos sinápticos penalizando cada neurônio segundo sua influência no erro geral, essa etapa é feita da camada de saída para a de entrada, retroativamente.

2.2.2 Rede de Hopfield

A rede de Hopfield é (a) uma forma de rede neural recorrente, isto é, determinadas conexões realimentam alguns neurônios, formando ciclos na rede; (b) apresenta um atraso temporal, ou seja, a propagação dos sinais não é instantânea e (c) a saída é um estado de convergência, isto é, após se apresentar uma entrada a rede opera em ciclos até que a saída não mude mais, situação onde se diz que a rede alcançou o equilíbrio.

ESQUEMA DE UMA REDE DE HOPFIELD AQUI

A rede de Hopfield funciona como uma memória endereçada por conteúdo, ou memória associativa, por exemplo, muitas vezes lembramos de fatos inteiros apenas com uma pequena lembrança do acontecimento. Uma memória associativa é, deste modo, um conjunto de padrões armazenados de tal modo que, quando se apresenta um novo padrão, a resposta será o padrão armazenado que seja mais parecido a este que foi apresentado.

Geralmente as redes de Hopfield não possuem um método de aprendizado associado, os pesos sinápticos são calculados por métodos matemáticos provenientes de sua definição formal. A definição formal garante que a rede sempre irá convergir, contudo, em algumas situações esta convergência pode não ocorrer para o padrão mais próximo da entrada, e ainda não existe um método conhecido que resolva este problema.

2.2.3 Redes de Kohonen

As redes de Kohonen apresentam apenas duas camadas de neurônios, a camada de entrada e a de saída. A camada de saída é uma espécie de malha de neurônios não conectados entre si, mas amplamente conectados com os neurônios da camada de entrada. Esta malha funciona como um mapa, onde para cada padrão de entrada apenas um neurônio é ativado, padrões semelhantes ativam neurônios dentro de uma mesma região da malha.

ESQUEMA DE UMA REDE DE KOHONEN AQUI

As redes de Kohonen possuem um algoritmo próprio de treinamento, dividido em três etapas; na primeira, chamado de processo competitivo, uma determinada entrada ativa apenas um neurônio da malha; na segunda, chamado de processo cooperativo, o neurônio escolhido estabelece uma vizinhança de neurônios que serão ajustados para, junto com ele, identificar padrões semelhantes ao que foi apresentado; e por fim, na terceira etapa, chamada de processo adaptativo, os pesos são atualizados com base no neurônio vencedor e na vizinhança topológica. Este algoritmo de treinamento é dito não supervisionado,

pois não depende de um par (*entrada, saída esperada*), já que a própria rede estabelece como será a configuração dos resultados.

2.3 Redes neurais de Kohonen

Esta seção irá apresentar mais detalhadamente como é a configuração de uma rede de Kohonen, seu algoritmo de treinamento e os usos comuns deste tipo de rede.

2.3.1 Topologia de uma rede de Kohonen

Como dito anteriormente, a rede de Kohonen apresenta apenas duas camadas de neurônios, a camada de entrada e a camada de saída. A camada de entrada deve possuir tantos neurônios quanto forem à quantidade de elementos do padrão de entrada. A camada de saída é uma grade de geometria livre, geralmente retangular, de neurônios que não estão ligados entre si, mas estão, cada um, ligados a todos os neurônios da camada de entrada. As conexões apresentam pesos para escalar o sinal enviado.

ESQUEMA DE UMA CONEXÃO DA REDE DE KOHONEN AQUI

2.3.2 Treinamento da rede

O treinamento requer que os pesos sinápticos sejam iniciados com valores bem pequenos, para que a rede não apresente inicialmente nenhuma configuração. Três processos são executados para cada entrada do conjunto de treinamento, o processo competitivo, o processo cooperativo e o processo adaptativo.

Processo competitivo

Quando uma entrada $x = [x_1, x_2, \dots, x_n]^T$ é apresentado à rede, o neurônio da grade que melhor responder a este padrão será ativado, este neurônio é dito vencedor, e será recompensado ajustando-se seus componentes para mais próximo do vetor de entrada.

O critério escolhido para determinar o neurônio vencedor é a distância euclidiana entre o vetor de entradas e o vetor de pesos das sinapses do neurônio, como indicado na

equação 2.1:

$$d_i(t) = \sqrt{\sum_{j=1}^N (x_j(t) - w_{ij}(t))^2} \quad (2.1)$$

Onde:

- $d_i(t)$ é a distância euclidiana entre o vetor de pesos do neurônio i e o vetor de entradas na iteração t ;
- i é o índice do neurônio da grade;
- j é o índice do neurônio de entrada;
- N é o número de entradas;
- $x_j(t)$ é o sinal de entrada na entrada j na iteração t ;
- $w_{ij}(t)$ é o valor do peso sináptico entre o neurônio de entrada j e o neurônio da grade i na iteração t .

Processo cooperativo

Estudos biológicos indicam que ao ser excitado, um neurônio estimula seus vizinhos topológicos, de forma que quanto mais próximo um neurônio está do neurônio ativo, mais excitado pelo estímulo do neurônio ativo ele é. O processo cooperativo busca simular este mecanismo biológico.

Em termos matemáticos, o que se deseja é um parâmetro h_{ik} , dito *vizinhança topológica*, que indica o grau de cooperação entre o neurônio vencedor i e o seu vizinho k , que deve ser simétrico em relação ao neurônio k e deve decrescer constantemente com o aumento da distância l_{ik} , até que $\lim_{l_{ik} \rightarrow \infty} h_{ik} = 0$. A função gaussiana 2.2 atende a estas duas exigências:

$$h_{ik} = e^{\left(\frac{l_{ik}^2}{2\sigma^2}\right)} \quad (2.2)$$

O parâmetro σ é denominado *largura efetiva da vizinhança*, e deve diminuir a cada iteração, indicando uma tendência de especialização da rede. Neste trabalho o parâmetro

σ é a equação 2.3:

$$\sigma(t) = \sigma_0 e^{t/\tau_l} \quad (2.3)$$

Onde:

- σ_0 é o valor inicial de σ ;
- t é a iteração atual;
- τ_l é uma constante de tempo.

Processo adaptativo

O processo adaptativo atualiza os pesos sinápticos a cada iteração, levando em consideração o neurônio vencedor e a vizinhança topológica. O ajuste dos pesos deve decrescer com o tempo, para evitar que novos dados comprometam seriamente o conhecimento já adquirido, substituindo padrões já estabelecidos por novos. Algo semelhante ocorre com o cérebro humano, ao decorrer do envelhecimento o aprendizado vai se tornando mais difícil.

O ajuste Δw_{ij} que a sinapse entre o neurônio de entrada i e um neurônio da malha j deve sofrer é expresso pela equação 2.4:

$$\Delta w_{ij} = \eta(t) h_{ik}(t) (x_j - w_{ij}) \quad (2.4)$$

Onde $h_{ik}(t)$ é o parâmetro vizinhança topológica na iteração t , referente ao neurônio vencedor k . O parâmetro *taxa de aprendizagem* $\eta(t)$ é definido pela expressão 2.5:

$$\eta(t) = \eta_0 e^{t/\tau_l}, \eta_0 \in [0, 1] \quad (2.5)$$

Onde τ_l é uma constante de tempo.

Algoritmo geral de treinamento

O algoritmo 1 resume as três etapas anteriores e descreve todo o processo de treinamento de uma rede de Kohonen:

Algorithm 1: Treinamento de uma rede de Kohonen

Entrada: σ_0 , τ_l , η_0 e o valor do *erro*

início

repita

 Calcular a *largura efetiva* $\sigma(t)$;

 Calcular a *vizinhança topológica* h ;

 Calcular a *taxa de aprendizado* $\eta(t)$;

para cada conexão faça

 Calcular Δw ;

 Ajustar o arco;

fim para cada

até *distâncias auchidianas* \leq *erro*;

fim

2.4 Descritores de Hu

Os descritores de Hu são um conjunto de sete momentos invariantes a rotação, translação e escala.

O momento bidimensional de ordem $(p + q)$ é dado pela equação 2.6:

$$m_{pq} = \iint x^p y^q f(x, y) dx dy, p, q \in \quad (2.6)$$

A equação num domínio discreto, pode ser reescrita na forma:

$$m_{pq} = \sum_{x,y} x^p y^q f(x, y), p, q \in \quad (2.7)$$

A massa total da função $f(x, y)$ é determinado pelo momento m_{00} , conforme a equação

2.8:

$$m_{pq} = \sum_{x,y} f(x,y), p, q \in \quad (2.8)$$

Existe um ponto no qual a aplicação pontual da massa total gera o mesmo momento que a massa distribuída, este ponto é dito centroide de $f(x,y)$ e suas coordenadas x e y são dadas pela equação 2.9:

$$\bar{x} = \frac{1}{m_{00}} \sum x f(x,y) = \frac{m_{10}}{m_{00}} \quad (2.9a)$$

$$\bar{y} = \frac{1}{m_{00}} \sum y f(x,y) = \frac{m_{01}}{m_{00}} \quad (2.9b)$$

O momento central é obtido se deslocando a imagem para o centroide, da seguinte forma:

$$\mu_{pq} = \sum_{x,y} (x - \bar{x})^p (y - \bar{y})^q f(x,y) \quad (2.10)$$

Ainda é necessário normalizar o momento para que os valores resultantes não sejam extremos a ponto de serem ignorados pelo sistema de reconhecimento de padrões. O momento central de ordem $(p+q)$ normalizado é obtido dividindo o momento central de y mesma ordem por um fator definido por μ_{00}^γ , conforme indicado pela equação 2.11:

$$\gamma = 1 + \frac{p+q}{2} \quad (2.11a)$$

$$\eta_{pq} = \frac{\mu_{pq}}{\mu_{00}^\gamma} \quad (2.11b)$$

A partir dessas equações são estabelecidos sete momentos invariantes à translação, rotação e escala, chamados de momentos de Hu, ou descritores de Hu. São eles:

$$\varphi_1 = \eta_{20} + \eta_{02} \quad (2.12a)$$

$$\varphi_2 = (\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2 \quad (2.12b)$$

$$\varphi_3 = (\eta_{30} - 3\eta_{12})^2 + (3\eta_{21} - \eta_{03})^2 \quad (2.12c)$$

$$\varphi_4 = (\eta_{30} + \eta_{12})^2 + (3\eta_{21} + \eta_{03})^2 \quad (2.12d)$$

$$\varphi_5 = (\eta_{30} - 3\eta_{12})(\eta_{30} + \eta_{12}) [(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] \quad (2.12e)$$

$$+ (3\eta_{21} - \eta_{03})(\eta_{21} + \eta_{03}) [3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] \quad (2.12f)$$

$$\varphi_6 = (\eta_{20} - \eta_{02}) [(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] \quad (2.12g)$$

$$+ 4\eta_{11}(\eta_{30} - \eta_{12})(\eta_{21} + \eta_{03}) \quad (2.12h)$$

$$\varphi_7 = (3\eta_{21} - \eta_{30})(\eta_{30} + \eta_{12}) [(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] \quad (2.12i)$$

$$+ (3\eta_{12} - \eta_{03})(\eta_{21} + \eta_{03}) [3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] \quad (2.12j)$$

2.5 Imagens digitais

Imagens digitais são representações computacionais de imagens bidimensionais, codificadas de modo a permitir seu armazenamento, exibição e manipulação por dispositivos eletrônicos. Há dois tipos fundamentais de imagens digitais, os mapas de bits (*bitmaps*) e as imagens vetoriais.

2.5.1 Mapas de bits

Mapa de bits é a representação matricial de uma imagem, onde cada posição, chamada de *pixel*, armazena uma cor. Normalmente os *pixels* são codificados no padrão RGB (*Red, Green, Blue*), que utiliza três *bytes* para armazenar um inteiro para as cores vermelha, verde e azul, respectivamente. Em mídias impressas é comum que as imagens *bitmaps* utilizem o padrão CMYK (*Cian, Magenta, Yellow, Black*) ao invés do RGB.

Embora uma imagem bitmap seja armazenada na RAM com todos os *pixels*, é comum, por uma questão de economia de memória e tempo de transmissão, a compressão destes arquivos. Entre os principais formatos de compressão estão o GIF (*Graphics Interchange Format*), o JPEG (*Joint Photographic Experts Group*) e o PNG (*Portable Network Graphics*).

2.5.2 Imagens vetoriais

As imagens vetoriais são formadas pela descrição geométrica de objetos. Por serem compostas de vetores, este tipo de imagem ocupa menos espaço na memória comparado com as bitmaps, e não perdem a qualidade quando aplicadas transformações de escala e rotação sobre elas.

Referências Bibliográficas